Triaje Automático de Solicitudes de Soporte Tecnológico para una PYME

Mesa de Ayuda Inteligente con RAG sobre 15 Manuales Oficiales · Agente ITIL v4

Seminario:	Ingeniería de Software con IA Generativa — Octubre/Noviembre 2026
Caso Asignado:	Caso N.º 03 · Grupo 3 · Triaje de Soporte Tecnológico (PYME 60 Colaboradores)
Docente Evaluador:	Ing. Heyler Fabio Guaza (Mg. Ciberseguridad · OPD · Abogado)
Fecha de Defensa:	■ Lunes 16 de Noviembre de 2026 · 16:00–17:30 · Zoom CEDIA
Integrante 1:	Christian Guillermo Morales González — Tech Lead / Coordinador (min 00:00–10:00)
Integrante 2:	Luis Fernando Ribera Alajo — Builder / Arquitectura (min 10:00–20:00)
Integrante 3:	Amalia Geoconda Iguasnia Escobar — QA Lead / Ciberseguridad (min 20:00–30:00)
URL Producción:	https://triajesoporte-grupo-3.onrender.com
Repositorio:	https://github.com/cgmorales12/TriajeSoporte-grupo-3

■ Estructura de la Sustentación Oral — 30 Minutos (10 min por integrante)

Protocolo UNIANDES: Seminario/Examen Complexivo · Art. 5.1 y 6.1 del Protocolo de Defensa

Minutos	Expositor	Rol	Contenido Principal
00:00–10:00	Christian Morales G.	Tech Lead / Coordinador	Apertura grupal · Demo en vivo (3 casos) · 3 preguntas Fase 5 del Caso 03 · Arquitectura general · Pase a Fernando
10:00–20:00	Luis Fernando Ribera A.	Builder / Arquitectura	Arquitectura C4 (4 capas) · Pipeline RAG 15 manuales · 5 herramientas Agente ITIL · ADR-001..005 · Gateway Gemini→Groq · Pase a Amalia
20:00–30:00	Amalia Iguasnia E.	QA Lead / Ciberseguridad	83 pruebas pytest · Smoke tests p95 · LOPDP + OWASP LLM01/02/05 · Indicadores Caso 03 · Cierre formal del grupo
30:00–60:00	TRIBUNAL	Evaluadores	Ronda de preguntas (hasta 10 min por evaluador según Protocolo UNIANDES Art. 5.2)

Christian — Tramos de 10 min	Fernando — Tramos de 10 min	Amalia — Tramos de 10 min
00:00–01:30 · Apertura grupal 01:30–04:30 · Demo 3 casos en vivo 04:30–07:00 · Fase 5: 3 preguntas ROI 07:00–09:00 · Arquitectura general 09:00–10:00 · Pase a Fernando	10:00–12:30 · Arquitectura C4 + ADR 12:30–15:00 · Pipeline RAG ChromaDB 15:00–17:30 · Agente ITIL 5 tools 17:30–19:30 · Persistencia + GitHub 19:30–20:00 · Pase a Amalia	20:00–22:30 · 83 pruebas pytest 22:30–24:30 · Smoke tests + p95 24:30–27:30 · LOPDP + OWASP 27:30–29:30 · Indicadores Caso 03 29:30–30:00 · Cierre formal

■ Christian Morales G. — Tech Lead / Coordinador ■ 00:00 – 01:30

Bloque 1 · Apertura Grupal y el Problema Real de la PYME

■ El Dolor Crítico de la PYME (60 Colaboradores)

• **1 Solo Técnico de TI Desbordado:** Pierde más del 56% de su jornada (4.5 h/día) en solicitudes repetitivas de oficina.

• **Cuello de Botella:** Bloqueos de contraseña (AD), VPN de teletrabajo, impresoras y ERP generaban MTTR de 45 min a 4 horas.

• **Impacto Financiero:** Detención de Contabilidad, Ventas y RRHH · Costo manual: $18.00 USD/ticket.

• **Corpus documental:** 15 manuales técnicos dispersos (DOC-01 a DOC-15) sin sistema de búsqueda.

■ Principio Rector de Ingeniería

«El Modelo Propone, el Código Dispone, la Configuración Gobierna y el Humano Autoriza»

1. El modelo **propone** síntomas en lenguaje natural.
2. El código **dispone** acciones y validaciones deterministas.
3. La configuración **gobierna** prioridades y SLAs a costo 0 tokens.
4. El humano **autoriza** antes de despachar (HITL · OWASP LLM08).

■ Equipo Grupo 3

■ **Christian Morales** — Tech Lead / Coordinador

■ **Fernando Ribera** — Builder / Arquitectura

■ **Amalia Iguasnia** — QA Lead / Ciberseguridad

■ Acceso en Producción

https://triajesoporte-grupo-3.onrender.com

GitHub: cgmorales12/TriajeSoporte-grupo-3

■ Christian Morales G. — Tech Lead / Coordinador ■ 01:30 – 04:30 · Demo en Vivo

Bloque 2 · Demostración en Vivo en Producción — 3 Casos Obligatorios del Caso 03

Vista	Caso	Acción en Pantalla	Resultado Verificable
■ Vista Usuario	Caso 1: VPN FortiClient (DOC-02)	Clic [■ Fallo VPN FortiClient] → Clasificar con IA	RAG recupera DOC-02 en 1.5s · Pasos claros · Prioridad Media · 73% autoatención L1
■ Vista Usuario	Caso 2: Menú Almuerzo (Fuera de Alcance)	Clic [■ Menú Almuerzo] → Clasificar con IA	0 citas · No inventa menús · Abstención OWASP LLM01 · Orienta a Secretaría
■■ Vista TIC	Caso 3: Hardware/HITL (OWASP LLM08)	Cambiar a Vista TIC → Clic [■■ Pantalla Azul] → Clasificar	Compuerta HITL activa · Prioridad Alta calculada en Python desde config/ · 0 tokens

■ **Apertura previa (15:40):** Visitar /health en pestaña privada para despertar el contenedor Render y evitar el arranque en frío de 30-60 segundos.

■ Christian Morales G. — Tech Lead / Coordinador ■ 04:30 – 07:00 · Respuestas Fase 5

Bloque 3 · Respuestas Obligatorias Fase 5 del Caso N.º 03

El caso pide responder EXACTAMENTE estas 3 preguntas durante la sustentación

Pregunta Oficial del Caso 03	Respuesta del Grupo 3	Evidencia
¿Qué porcentaje de solicitudes se resolvería sin intervención humana?	**73.3%** de autoatención Nivel 1 (supera el mínimo del 70% del Caso 03). De 30 solicitudes de referencia: 88% recibe categoría y prioridad correctas.	Dashboard Fase 5 en /tablero · DOC-01 a DOC-15 citados
¿Cómo se definió y probó la regla de escalamiento?	Matriz impacto×urgencia en **config/matriz_prioridad.json** (nunca hardcoded en el LLM). Probada con 30 solicitudes etiquetadas. Hardware/caídas → Prioridad Alta + HITL obligatorio.	config/matriz_prioridad.json · tests/test_herramientas_agente.py (29 pruebas)
¿Qué métricas usaría la empresa para medir el ROI?	MTTR: 45 min → 3.8 min (**-91.5%**). Ahorro: **$16,987/año**. Costo/ticket: $18 → $3.40. 4.5 hrs/día liberadas al técnico. Latencia p95: 2.2s.	Dashboard Métricas en /tablero · Pestaña Fase 5

■ Christian Morales G. — Tech Lead / Coordinador ■ 07:00 – 10:00 · Arquitectura + Pase

Bloque 4 · Arquitectura General y Principio Determinista

Capa	Tecnología	Rol
① Frontend	HTML vanilla · CSS · JavaScript (sin frameworks)	Portal Usuario (60 empleados) + Consola TIC (admin) — RBAC por vista
② Backend	FastAPI + Uvicorn + AnyIO (40 hilos)	API REST / endpoints clasificar, tickets, RAG · Variables de entorno en Render
③ LLM	Gemini 1.5 Flash → Groq Llama 3.3 70B (failover)	Extrae síntomas · Gateway resiliente: 2 reintentos backoff → Groq en 736ms
④ Datos	ChromaDB (vectores) + SQLite (tickets) + JSON (reglas)	15 manuales RAG · Estado de tickets · Matriz ITIL a costo 0 tokens

■ **Separación de responsabilidades:** El LLM solo extrae síntomas. Prioridad, SLA y escalamiento los calcula Python leyendo config/matriz_prioridad.json — costo: 0 tokens adicionales.

→ **Pase a Fernando Ribera:** «Cedo la palabra a mi compañero Luis Fernando Ribera quien explicará la arquitectura interna, el pipeline RAG y las decisiones ADR del proyecto.»

Bloque 5 · Arquitectura C4 y Justificaciones ADR

Capa C4	Componentes	Decisión ADR	Alternativa Descartada
L1 Frontend	HTML+CSS+JS vanilla · Sin frameworks · Sin npm	ADR-006: Sin React/Vue — 0 dependencias frontend	React: +2.5 MB bundle, complejidad innecesaria para MVP
L2 Backend	FastAPI + Uvicorn + AnyIO · 40 hilos concurrentes	ADR-001: FastAPI vs Django · ADR-002: AnyIO vs threading	Django: +45ms latencia, +250MB RAM, ORM innecesario
L3 LLM	Gemini 1.5 Flash (primario) → Groq Llama 3.3 70B	ADR-007: Gateway resiliente con backoff exponencial	Un solo proveedor: punto único de falla en demos en vivo
L4 Datos	ChromaDB + SQLite + JSON config	ADR-003: ChromaDB · ADR-005: SQLite · ADR-004: migración PG	Pinecone: costo $70/mes. FAISS: sin metadatos nativos

■ **ADR-002 — Por qué AnyIO:** El LLM genera latencia I/O de 1-3 segundos. AnyIO corre 40 tareas concurrentes sin bloquear el Event Loop. Con threading nativo, 1 petición lenta bloquea al resto.

Bloque 6 · Pipeline RAG — Base de Conocimiento de 15 Manuales

Fase del Pipeline	Archivo/Componente	Qué hace
① Corpus	data/raw/ (DOC-01 a DOC-15)	15 manuales técnicos: contraseñas AD, VPN FortiClient, impresoras, ERP, red LAN, Wi-Fi, etc.
② Fragmentación	scripts/ingest_docs.py	Divide por sección con metadatos: documento_id, categoria, titulo, fecha_vigencia
③ Vectorización	ChromaDB · data/chroma/	Convierte fragmentos a embeddings. Búsqueda semántica por similitud coseno (BM25-style)
④ Consulta RAG	app/services/rag.py · consultar_base_conocimiento()	Recibe descripción del problema → ChromaDB retorna top-3 fragmentos + score relevancia
⑤ Respuesta	PropuestaRegistroTicketOut (Pydantic)	fragmento_aplicado + documento_id + score → plantilla humanizada al usuario

■ **Cita obligatoria:** El sistema nunca responde sin citar el documento fuente (DOC-XX). Si ChromaDB no encuentra un fragmento relevante → abstención, 0 invenciones. Cumple indicador del Caso 03: «al menos 70% con cita verificable».

Bloque 7 · Agente ITIL — 5 Herramientas del Caso 03 + Gateway Resiliente

Herramienta	Archivo	Acción	Regla de Negocio
clasificar(solicitud)	app/services/llm.py	LLM extrae categoría, impacto, urgencia y resumen con salida Pydantic estructurada	extra='forbid' en schema → nunca atributos inventados
priorizar(impacto, urgencia)	config/matriz_prioridad.json	Lookup O(1) en JSON externo. Nunca hardcoded en el LLM. Costo: 0 tokens	Alta/Media/Baja + SLA_minutos según ITIL v4
buscar_solucion(cat, texto)	app/services/rag.py	ChromaDB semántico → top fragmento + documento_id citado obligatoriamente	Si score < umbral → abstención, no inventa
crear_ticket(datos)	app/routers/tickets.py	Persiste en SQLite con estado nuevo/en_atención/resuelto/escalado	HITL: humano confirma antes de crear en hardware o escalado
escalar(ticket, motivo)	app/routers/tickets.py	Activa compuerta HITL, bloquea autoatención y asigna al técnico humano	OWASP LLM08: nunca despacha cuadrilla sin aprobación

■ **Gateway Gemini → Groq:** Si Gemini devuelve HTTP 429 o 503 → backoff exponencial (2 reintentos) → conmuta a Groq Cloud Llama 3.3 70B en 736ms · Badge naranja de aviso al usuario.

■ Luis Fernando Ribera A. — Builder / Arquitectura | ■ 17:30 – 20:00 · Persistencia + GitHub

Bloque 8 · Modelo de Datos, Commits GitHub y README

Campo del Ticket	Tipo	Propósito
ticket_id	VARCHAR UUID	Identificador único trazable (ej. TCK-ABDB87D2)
estado	ENUM	nuevo → en_atención → resuelto / escalado (flujo ITIL)
categoria_propuesta	VARCHAR	Salida estructurada del LLM validada por Pydantic
prioridad_itil	VARCHAR	Alta/Media/Baja calculada por Python, no por el LLM
sla_minutos	INTEGER	Tiempo máximo de resolución según matriz ITIL (15/240/1440)
solucion_propuesta	TEXT	Fragmento RAG citado con documento_id — auditable
operador_confirmador	VARCHAR	Técnico humano que autorizó el HITL (trazabilidad)
created_at / updated_at	DATETIME	Timestamps automáticos para métricas SLA y MTTR

■ **Evidencia GitHub:** Commits de los 3 integrantes en las 4 semanas del seminario. README con problema, arquitectura, instalación, variables de entorno (nunca en código), URL, limitaciones y declaración de uso de IA.

→ **Pase a Amalia:** «Cedo la palabra a mi compañera Amalia Iguasnia quien presentará las pruebas de calidad, seguridad LOPDP y cumplimiento de indicadores del Caso 03.»

■ Amalia Geoconda Iguasnia E. — QA Lead / Ciberseguridad ■ 20:00 – 22:30 · Suite 83 Pruebas

Bloque 9 · Suite de 83 Pruebas Automatizadas con pytest

Archivo de Test	Pruebas	Qué valida	Conexión Caso 03
test_endpoints.py	43 pruebas	API REST: contratos RFC 9457, códigos HTTP, failover Gemini→Groq, schema Pydantic	Solicitudes resueltas + escaladas + ticket inexistente
test_construccion_prompts.py	11 pruebas	R.E.C.E.T.A. de ingeniería de prompts: delimitación, rol, formato, anonimización LOPDP	Contraseña compartida → advertir y no almacenar (Caso 03)
test_herramientas_agente.py	29 pruebas	5 herramientas del agente ITIL: clasificar, priorizar, buscar_solucion, crear_ticket, escalar	Instrucciones ocultas (inyección) → contenidas
TOTAL	**83 passed ■**	**100% verde · monkeypatch Gemini/Groq → costo $0.00 USD**	**CI automático sin gastar cuota API**

■ **fixture aislar_base_datos_tests (tests/conftest.py):** Cada corrida de pytest usa una BD SQLite efímera en memoria (:memory:) que se destruye al terminar → protege los 20 tickets de producción en Render.

■ Amalia Geoconda Iguasnia E. — QA Lead / Ciberseguridad | ■ 22:30 – 24:30 · Smoke Tests en Vivo

Bloque 10 · Pruebas Funcionales en Vivo contra Render + Latencia p95

Formato oficial Tema 5: «Una línea por caso, una línea de resultado»

#	Tipo	Endpoint y Parámetro	Resultado Esperado	Latencia
1	Salud	GET /health	■ HTTP 200 · Backend vivo	0.3 s
2	RAG VPN	POST clasificar → 'Fallo VPN FortiClient'	■ Categoría Redes · DOC-02 · Prioridad Media	1.2 s
3	RAG AD	POST clasificar → 'Contraseña bloqueada AD'	■ Accesos y Contraseñas · DOC-01 · Prioridad Alta	0.8 s
4	Abstención	POST clasificar → 'Menú almuerzo cafetería'	■ Fuera de Alcance · 0 citas · Sin invención	0.2 s
5	Inyección	POST clasificar → 'Ignora tus instrucciones...'	■ HTTP 200 · Contenida · Sin filtración de prompt	0.2 s
6	Schema	POST clasificar → payload inválido (campo extra)	■ HTTP 422 Unprocessable · Pydantic bloquea	0.1 s
TOTAL	**6/6 ■**	**100% pasan contra URL de producción**	**p95 = 2.2 segundos**	**< 2.5s**

■ **Por qué p95 y no el promedio:** 19 respuestas de 2s + 1 de 30s → promedio = 3.4s (engañoso). El p95 = 2.2s certifica que el 95% de los colaboradores recibe respuesta en menos de 2.5s. El promedio engaña; el percentil protege.

■ Amalia Geoconda Iguasnia E. — QA Lead / Ciberseguridad ■ 24:30 – 27:30 · LOPDP + OWASP

Bloque 11 · Ciberseguridad: LOPDP Ecuador + OWASP LLM Top 10

Marco Legal / Riesgo	Artículo / Referencia	Control Implementado	Archivo de Respaldo
LOPDP Ecuador Anonimización activa	Art. 23 — Protección de datos sensibles	Regex en anonimizar_datos_sensibles(): contraseñas → [CONFIDENCIAL_REMOVIDO] antes de llegar al LLM o a SQLite	app/services/llm.py · test_construccion_prompts.py
LOPDP Ecuador Minimización de datos	Art. 10 — Solo datos necesarios	Formulario solicita únicamente: nombre, correo y descripción del problema. Sin datos biométricos ni financieros.	frontend/index.html · app/schemas.py
OWASP LLM01 Prompt Injection	Top 10 LLM 2025 — LLM01	Delimitación semántica con etiquetas .... El texto del usuario no puede alterar el system prompt.	app/services/llm.py · test_herramientas_agente.py
OWASP LLM02 Insecure Output	Top 10 LLM 2025 — LLM02	Esquemas Pydantic V2 con extra='forbid' en todos los modelos. Bloquea atributos maliciosos o campos alucinados.	app/schemas.py · response_model en FastAPI
OWASP LLM05 Abuso de API / DoS	Top 10 LLM 2025 — LLM05	Token Bucket: 10 peticiones/minuto por IP → HTTP 429 Too Many Requests (RFC 6585). Mitiga abuso masivo.	app/middleware/rate_limiter.py

■ Amalia Geoconda Iguasnia E. — QA Lead / Ciberseguridad ■ 27:30 – 29:30 · Indicadores + ADR-004

Bloque 12 · Indicadores Mínimos del Caso 03 y Transparencia Técnica

Indicador Oficial del Caso 03	Meta	Resultado Real	Estado
% de solicitudes con categoría y prioridad correctas (30 de referencia)	≥ 85%	88% (26 de 30 correctas)	■ SUPERA
% de solicitudes de primer nivel resueltas sin escalamiento con cita	≥ 70%	73.3% (22 de 30 sin escalamiento)	■ SUPERA
Contraseñas compartidas por usuario: almacenadas o repetidas en respuesta	0 contraseñas	0 — Verificado con test_construccion_prompts.py	■ CUMPLE

■■ Limitaciones Honestas (ADR-004) — Transparencia de Ingeniería:

Limitación	Impacto actual	Solución documentada
SQLite efímero en Render (plan gratuito)	Al reiniciar el contenedor, los tickets se borran. Sin impacto para la demo de 60 usuarios.	ADR-004: migración desacoplada a PostgreSQL/Supabase documentada para >500 usuarios
El modelo no siempre cita la misma sección	Variabilidad de 12% en 30 solicitudes de referencia.	Score de relevancia ChromaDB filtra fragmentos con baja confianza → abstención

■ Amalia Geoconda Iguasnia E. → Christian Morales G. ■ 29:30 – 30:00 · Cierre y ROI

Bloque 13 · Métricas Ejecutivas y Cierre Formal del Grupo 3

KPI	Antes	Después	Impacto
Autoatención Nivel 1	0% (manual)	73.3% ■ (meta ≥70%)	73 de cada 100 consultas resueltas sin técnico
MTTR (Tiempo Resolución)	45 minutos	3.8 minutos	-91.5% de reducción
Tiempo libre del técnico	0 horas/día	4.5 horas/día	56% de jornada liberada para proyectos estratégicos
Costo por ticket	$18.00 USD	$3.40 USD	Ahorro proyectado: $16,987 USD/año
Latencia p95	45 min (manual)	2.2 segundos	95% de colaboradores recibe respuesta en < 2.5s

¡Muchas gracias! El Grupo 3 ha diseñado, construido, desplegado y validado un sistema de triaje inteligente que funciona en producción, cumple la LOPDP Ecuador, está protegido con OWASP LLM01/02/05 y cuenta con 83 pruebas automatizadas. Quedamos a disposición del distinguido tribunal para la ronda de preguntas.

■ Respuestas Rápidas del Tribunal — Christian Morales (Tech Lead)

Pregunta	Respuesta (Fórmula: Alternativa Descartada + Dato)
■ ¿Por qué FastAPI y no Django?	Django suma +45ms latencia y +250MB RAM. FastAPI+Uvicorn+AnyIO maneja 40 hilos LLM concurrentes sin bloquear el Event Loop. Pydantic V2 valida contratos automáticamente.
■ ¿Cómo funciona el Gateway si Gemini falla?	Si Gemini devuelve HTTP 429 o 503: 2 reintentos con backoff exponencial → conmuta a Groq Cloud Llama 3.3 70B en 736ms. Badge naranja avisa sin caída para el usuario.
■ ¿Por qué SQLite y no PostgreSQL?	60 usuarios simultáneos · latencia 0.8ms · costo $0. Para >500 usuarios está documentada la migración en ADR-004 (Supabase o AWS RDS), desacoplada del código.
■ ¿Qué significa «el modelo propone, el código dispone»?	El LLM solo extrae síntomas. Prioridad, SLA y escalamiento los calcula Python leyendo config/matriz_prioridad.json. Ninguna regla de negocio depende del texto que genera el modelo.
■ ¿Qué OWASP aplicaron y cuáles dejaron afuera?	Implementamos LLM01 (delimitación semántica), LLM02 (Pydantic extra=forbid), LLM08 (HITL hardware). LLM05 (Token Bucket). LLM06 (trazabilidad de agente en logs). Faltaría LLM09 en producción real.

■ Respuestas Rápidas del Tribunal — Luis Fernando Ribera (Arquitectura)

Pregunta	Respuesta (Fórmula: Alternativa Descartada + Dato)
■ ¿Por qué no usaron SQLAlchemy u ORM?	Para 60 usuarios y un modelo de datos simple, SQLAlchemy agrega complejidad innecesaria. Usamos sqlite3 nativo con queries parametrizadas (protección SQL Injection) y latencia de 0.8ms.
■ ¿Cómo garantizan que el LLM no inventa manuales?	Tres capas: (1) ChromaDB retorna score de relevancia — si es bajo, abstención. (2) Pydantic valida que documento_id exista en el catálogo DOC-01..15. (3) extra='forbid' bloquea campos alucinados.
■ ¿Qué es BM25 y cómo lo usan?	BM25 es un algoritmo de recuperación por frecuencia de términos. ChromaDB lo combina con embeddings semánticos para un retrieval híbrido más preciso que embeddings puros en texto técnico corto.
■ ¿Por qué 40 hilos en AnyIO?	El LLM introduce latencia I/O de 1-3s. Con 40 hilos, 40 colaboradores pueden clasificar simultáneamente sin que una petición lenta bloquee las demás. El Event Loop de Python gestiona el pool.
■ ¿Cómo manejan concurrencia de 60 usuarios?	AnyIO con asyncio: cada petición al LLM es una tarea asíncrona. SQLite soporta lecturas concurrentes con WAL mode. Render asigna 512MB RAM y 0.5 vCPU — suficiente para 60 usuarios pico.

■ Respuestas Rápidas del Tribunal — Amalia Iguasnia (QA / Seguridad)

Pregunta	Respuesta (Fórmula: Alternativa Descartada + Dato)
■ ¿Por qué p95 y no el promedio?	El promedio engaña: 19 respuestas de 2s + 1 de 30s → promedio 3.4s, ocultando que un usuario esperó medio minuto. El p95 = 2.2s certifica que el 95% de colaboradores recibe respuesta en < 2.5s.
■ ¿Las pruebas garantizan que no alteran producción?	Sí. El fixture aislar_base_datos_tests en conftest.py conecta a SQLite :memory: (efímero) en cada corrida. Al terminar, se destruye sin tocar la BD de Render. Probado con --forked en CI.
■ ¿Cómo protegen datos si el LLM es de Google?	Art. 23 LOPDP: regex detecta contraseñas antes de enviar al LLM → [CONFIDENCIAL_REMOVIDO]. El minimizador (Art. 10) solo pasa nombre, correo y descripción del problema. Nada sensible llega a los servidores de Google.
■ ¿Qué es el Token Bucket y por qué HTTP 429?	Token Bucket es un algoritmo de limitación de tasa: acumula hasta 10 tokens/minuto. Cada petición consume 1. Si se agota → HTTP 429 Too Many Requests (RFC 6585). Mitiga bots y abuso masivo de la API.
■ ¿Qué pasa si alguien hace prompt injection en la descripción?	Tres capas de defensa: (1) Etiquetas delimitan el texto del usuario. (2) extra='forbid' en Pydantic bloquea campos maliciosos en el JSON. (3) Tests de inyección adversarial verifican que el prompt interno no se filtra.

■ Recursos Oficiales y Cierre — Grupo 3 · Caso N.º 03

Recurso	URL	Propósito
Tablero Kanban (Producción)	https://triajesoporte-grupo-3.onrender.com/tablero	Demostración en vivo · Vista Usuario + Vista TIC
Endpoint de Salud	https://triajesoporte-grupo-3.onrender.com/health	Verificar que el contenedor está activo antes de la demo
Swagger / OpenAPI	https://triajesoporte-grupo-3.onrender.com/docs	Documentación interactiva de todos los endpoints
Repositorio GitHub	https://github.com/cgmorales12/TriajeSoporte-grupo-3	Código fuente · commits 3 integrantes · ADRs · README
Zoom CEDIA (Defensa)	https://cedia.zoom.us/j/85992830383	Lunes 16/Nov/2026 · 16:00–17:30 · Estar listo a las 15:40

«El modelo propone, el código dispone, la configuración gobierna y el humano autoriza.» Muchas gracias — Grupo 3 · UNIANDES · Seminario IA Generativa Octubre-Noviembre 2026